

Тема 2. «Основы математической статистики»

Вторая тема нашего вводного курса посвящена математической статистике — науке о методах сбора, систематизации и анализа данных, позволяющих выявлять закономерности и зависимости в наблюдаемых явлениях.

Методы сбора информации влияют на последующие статистические характеристики и показатели. Математическая статистика используется как для описания и сравнения данных в ходе исследования, так и для интерпретации полученных результатов.

После освоения материала темы вы научитесь:

- Отличать номинальные, порядковые и количественные данные и выбирать корректные показатели.
- Объяснять разницу между средним, медианой и модой и выбирать подходящее «типичное».
- Оценивать разброс (SD, IQR) и объяснять, почему он важен для устойчивости результата.
- Читать гистограммы, box-plot и scatter-plot и делать краткую интерпретацию.
- Видеть связь (Пирсон) и не путать её с причинностью.

План занятия

- [Основы математической статистики](#)
- [Типы данных и шкалы измерений](#)
- [Центральные тенденции: среднее, медиана, мода](#)
- [Разброс: дисперсия, стандартное отклонение, межквартильный размах](#)
- [Корреляция: идея, знак, величина \(и предостережение\)](#)

Основные термины

- **Математическая статистика** — раздел математики, который разрабатывает методы сбора, систематизации, обработки и интерпретации данных наблюдений для выявления закономерностей.

- **Среднее значение (mean)** — это такая величина, которая показывает, каким бы было каждое из чисел, если бы весь общий “объем” распределить поровну между всеми.
- **Медиана (median)** — это значение, которое делит упорядоченный ряд данных на две равные части: половина значений меньше нее, половина — больше.
- **Выброс (outlier)** — это наблюдение, заметно отличающееся от основной массы данных и выбивающееся из общего распределения.
- **Абсолютный ноль** — это минимально возможное значение шкалы измерений, ниже которого наблюдения не могут существовать по определению (например, нулевая температура по шкале Кельвина или отсутствие массы).

1. Основы математической статистики

Математическая статистика — раздел математики, который разрабатывает методы сбора, систематизации, обработки и интерпретации данных наблюдений для выявления закономерностей.

Методы сбора информации влияют на последующие статистические характеристики и показатели. Математическая статистика используется как для описания и сравнения данных в ходе исследования, так и для интерпретации полученных результатов.

Где применяется математическая статистика?

В повседневной жизни мы нередко делаем выводы на основе интуиции, например: «Группа А занималась дольше — значит, её результаты лучше» или «Лечение В выглядит эффективнее». Статистика даёт возможность проверить такие предположения с помощью количественных методов и представить их в виде наглядных чисел и графиков.

Однако существует ряд распространенных ошибок, с которыми мы регулярно сталкиваемся:

- **Ловушка среднего**

В одном отделении больницы посчитали среднюю продолжительность госпитализации. Она оказалась 12 дней. На первый взгляд может показаться, что именно столько обычно лежит пациент. Но если посмотреть внимательнее, большинство пациентов выписывались уже через 5-6 дней, а несколько тяжелых случаев с пребыванием более 100 дней сильно увеличили среднее. В результате среднее значение не отражало «типичного» времени лечения.

На практике такая ситуация часто возникает при асимметричных данных (например,

доходы, сроки ожидания) или при наличии выбросов. В этих случаях среднее искажает реальную картину.

Что делать? Смотреть на медиану и квантили (см. Разделы 4 и 5), исследовать распределение на гистограммах и box-plot (см. Раздел 5), а также использовать устойчивые оценки вроде усечённого среднего или винзоризации.

- **Ложная корреляция**

Изучалась корреляция (см. Разделы 5 и 7) между числом аистов, свивших гнезда в южных районах Швеции, и рождаемостью в эти же годы в Швеции. Вычисления показывают совместные изменения этих показателей, то есть с ростом числа аистов в Швеции, растёт и число новорожденных. Однако мы не можем говорить о причинной зависимости полагаясь на наблюдаемое совместное изменение величин. И действительно, оказалось, что одновременные синхронные изменения числа аистов и детей объясняются изменением среднего уровня жизни жителей Стокгольма. При исключении этой искажающей переменной прежней корреляции уже не наблюдалось.

Что делать? Формулировать гипотезы, контролировать ключевые факторы, при необходимости переходить к моделированию и проверке гипотез.

Для чего нужна математическая статистика:

Математическая статистика пригодится в условиях неопределенности как инструмент принятия решений.

- Анализ данных
 - Проверка гипотез о поведении пользователя (A/B-тесты)
 - Построение доверительных интервалов и оценка значимости различий
- Работа с текстами и сигналами
 - Статистические языковые модели (n-граммы, оценка вероятности слов в тексте)
 - Оценка качества распознавания речи или машинного перевода (метрики BLEU, WER)
- Компьютерные науки и разработка
 - Приложение алгоритмов с вероятностной природой (MinHash, случайные леса)
 - Анализ производительности сервиса (квантили по времени отклика)

- Контроль ошибок и надёжности системы (оценка MTBF, времени простоя)
- Финансы и бизнес-аналитика
 - Прогнозирование (модели временных рядов)
 - Оценка рисков, волатильности портфеля
 - Проведение исследования идей

2. Типы данных и шкалы измерений

Данные поступают из самых разных источников. Это могут быть числовые показатели (например, показания счетчиков, измерения температуры или анализ крови), события (посещаемость сайта, загруженность зала обслуживания), а также тексты, изображения или видео.

Значительная часть информации приходит в неструктурированном виде. Тексты состоят из последовательностей символов и разделов, но не имеют единой формы, удобной для сравнения; изображения и видео тем более не сводятся напрямую к числам. Поэтому такие данные называют сырыми.

Основная задача науки о данных — преобразовывать сырой поток информации в структурированные формы, с которыми можно работать. Наиболее привычная форма — таблица со строками и столбцами, но также часто используются временные ряды или графовые структуры.

Данные делятся на типы – это формат представления данных, который определяет, что именно мы измеряем. Типы могут быть представлены в различных шкалах – это способ интерпретации данных и правила, по которым данные представлены. В статистике выделяют 2 типа данных и 4 шкалы измерения.

Логичен вопрос: «Зачем делить данные по типам и измерять их в разных шкалах?».

Дело в том, что различные типы и шкалы задают различные операции, которые можно с ними совершать: так, например, где-то уместно только «считать и проверять на равенство» (цвет глаз), где-то ещё и упорядочивать (рост, позиция в рейтинге), где-то — прибавлять/вычитать (температура в °C), а где-то — делить и говорить «в два раза больше» (время, деньги). Деление на типы и шкалы защищает нас от нелепых выводов: «средний любимый цвет», «20 °C — это в 2 раза теплее, чем 10 °C» и т. п.

Рассмотрим типы данных и шкалы, в которых они могут быть выражены.

1. Качественные (категориальные) данные:

- **Номинальная шкала** — просто названия, без порядка.
Примеры: пол (муж/жен), цвет глаз (карие/голубые/зеленые).

- **Порядковая (ранговая) шкала** — категории с порядком, но без точных интервалов.

Примеры: уровень образования (бакалавр < магистр < кандидат), оценка удовлетворенности (низкая/средняя/высокая).

2. Количественные (числовые) данные:

- **Интервальная шкала** — числовые данные с равными интервалами, но без абсолютного нуля.

Примеры: температура в градусах Цельсия или Фаренгейта.

- **Шкала отношений** — числовые данные с равными интервалами и с абсолютным нулем.


Примеры: вес, рост, возраст, доход.

3. Выборка данных

Еще одно важное понятие математической статистики — выборка.

Выборка — подмножество данных из генеральной совокупности. Популяция часто именуется **генеральной совокупностью**, другими словами это все возможные значения выборки.

Популярное мнение ошибочно утверждает, что эра больших данных сводит на нет потребность в выборке. Но на самом деле быстрое распространение данных переменного качества и релевантности только укрепляет потребность в выборке, как в инструменте эффективной работы с разнообразными данными и минимизацией смещения. Представленная схема подкрепляет этот факт:



Слева представлена популяция, которая в статистике предположительно подчиняется базовому, но при этом неизвестному закону. Единственное, что имеется, это выборка данных, и ее эмпирическое распределение (справа). Чтобы попасть из левой стороны в правую, используется процедура отбора (оранжевая стрелка).

Главная задача процедуры отбора данных в выборку заключается в том, чтобы исследуемые выборки могли дать нам как можно более точное представление о генеральной совокупности.

Выборка считается **репрезентативной**, если у каждого элемента генеральной совокупности равные шансы попасть в выборку.

Качество данных часто имеет большее значение, чем их количество, когда выполняется оценка, либо создается модель на основе выборки.

4. Центральные тенденции: среднее, медиана, мода

Когда мы хотим описать «типичное» значение в наборе данных, мы обращаемся к мерам центральной тенденции — это то, что позволяет кратко охарактеризовать распределение.

Разберём три основные меры:

1. **Среднее** (арифметическое)

$$\bar{x} = \frac{1}{n} \sum_{i=0}^n x_i$$

Где:

$\bar{x}$ — среднее,

x_i — значение наблюдения,

n — количество наблюдений.

Хорошо работает при симметричных распределения без выбросов, однако чувствительно к экстремальным значениям — несколько больших наблюдений могут сместить оценку.

Пример:

Рядовой посетитель бара в субботний вечер тратит 1200 рублей. За день в баре было 15 посетителей, в этот день в бар пришел Билл Гейтс и потратил 15000 рублей.

Посчитаем средний чек за день: $\frac{1200 \times 14 + 15000}{15} \sim 2120$ рублей.

На первый взгляд можно заключить, что «каждый клиент стал тратить на 920 рублей больше».

Однако в реальности поведение большинства посетителей не изменилось. Рост среднего значения объясняется лишь одним выбросом — редким событием, которое вряд ли повторится на следующий день.

В подобных ситуациях уместнее ориентироваться на медиану или распределение чеков по группам. Эти показатели лучше отражают «типичное» значение и менее чувствительны к разовым крайним наблюдениям.

2. Медиана

Это центральное значение, которое делит отсортированную выборку на две равные части, то есть 50% наблюдений выше этого значения и 50% наблюдений ниже.

Медиана устойчива к выбросам.

Рассчитаем медиану для примера выше:

[1200, 1200, 1200, 1200, 1200, 1200, 1200, **1200**, 1200, 1200, 1200, 1200, 1200, 1200, 15000].

1200 соответствует медианному значению. Теперь типичный чек за день составляет 1200 рублей.

Примечание: в случае, если выборка имеет четное кол-во элементов, медианой будет среднее значение элементов $n / 2$ и $n / 2 + 1$.

Пример с чётным числом элементов

[5, 7, 9, 11].

Центральные элементы: 7 и 9.

Медиана = $(7 + 9) / 2 = 8$.

3. Мода

Модой называется самое частое значение, которое встречается в выборке.


Примеры:

Выборка 1 = [1,0,0,0,0,0,3,6,8,10]; Мода = 0.

Выборка 2 = [Комод, Шкаф, Комод, Картина, Дом, Стена, Шкаф]; Мода = [Комод, Шкаф].

Инфографика

1:



Рассмотрим следующий пример с результатами экзамена студентов.

Обозначения:

Ось X — «Баллы (0–100)», ось Y — «Частота»

Легенда: «Результаты экзамена»

Описание:

Перед нами представлена гистограмма распределения оценок. Столбец обозначает кол-во значений в интервале. Интервалы одинаковы для каждого столбца. Гистограмма показывает приближенное описание распределения делая его более гладким.

Распределение, в целом, похоже на нормальное (колоколообразное), но видно:

1. несколько выбросов с малыми значениями (например, балл 5–10),
2. максимальный балл 100 — тоже выброс (слишком часто).

В такой ситуации:

- Среднее подскажет «общий уровень» ~ 73.4,
- Медиана даст представление о «типичном результате» ~ 74.5,
- Мода покажет, какой балл встречался чаще всего = 100, т.к. более 130 студентов получили наивысший балл.

Вопрос 1:

Чему равно среднее значение для набора данных ниже?

$X = \{12, 13, 13, 14, 14, 15, 16, 100\}$

Выберите один правильный вариант:

- A. 13.9
- B. 14
- C. 24.6

Вопрос 2:

Для того же набора данных чему равна медиана?

Выберите один правильный вариант:

- A. 13
- B. 14
- C. 24.6

Вопрос 3:

Какая мода у этого же набора данных?

Выберите один правильный вариант:

- A. 13 и 14
- B. 14 и 15
- C. 100

Вопрос 4:

Подумайте, что изменится, если убрать выброс (100), и сделайте вывод, какой показатель устойчивее к выбросам.

5. Разброс: дисперсия, стандартное отклонение, межквартильный размах

С центральной тенденцией разобрались. Однако, этого недостаточно для описания распределения. Рассмотрим следующую ситуацию. Допустим, два программиста получают в среднем 200 тысяч рублей в месяц. Но первый — стабильную зарплату, а у второго то густо, то пусто: фриланс, авансы, бонусы, задержки...

Среднее одно, а жизнь — разная. В статистике эта разница — это разброс. Он показывает, насколько значения "скачут" относительно среднего. Именно разброс часто отличает «предсказуемое» от «лотереи».

Как описать распределение?

Чтобы описать распределение чисел (например, доходов, времени отклика API или результатов теста), минимум нужно два параметра:

1. Центр (например, среднее, медиана) — где «в среднем» находятся значения.
2. Разброс — насколько они далеки от центра.

Иногда добавляют третий параметр — асимметрию (если распределение «косит» влево или вправо), и четвертый — эксцесс (похожесть на нормальное по «пиковости»). Но двух первых — уже достаточно, чтобы начать думать здраво.

Базовые статистики разброса:

1. Дисперсия

$$D(x)^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

Показывает средний квадрат отклонения от среднего значения. Чем значение больше, тем больше разброс вокруг среднего значения. Эта формула характеризует одним числом, как сильно по квадратичной мере значения выборки отклоняются от среднего.

Особенности:

- Измеряется в квадрате единиц. Если данные в рублях, дисперсия — в рублях², что затрудняет интерпретацию.
- Чувствительна к выбросам — большие отклонения влияют квадратично, т.к. разница возводится в квадрат.
- Часто используется как промежуточный шаг — например, для вычисления стандартного отклонения.

Пример поведения:

$$X = \{2, 4, 4, 4, 5, 5, 7, 9\}$$

1. Рассчитаем среднее

$$\bar{x} = \frac{2+4+4+4+5+5+7+9}{8} = \frac{40}{8} = 5$$

2. Подсчитаем отклонение каждого числа от среднего

$$x_i - \bar{x} = \{-3, -1, -1, -1, 0, 0, 2, 4\}$$

3. Возведем отклонения в квадрат

$$(x_i - \bar{x})^2 = \{9, 1, 1, 1, 0, 0, 4, 16\}$$

4. Рассчитаем дисперсию

$$D(x) = \frac{9+1+1+1+0+0+4+16}{8} = \frac{32}{8} = 4$$

Результат: 4.

2. Стандартное отклонение

$$\sigma = \sqrt{D(x)}$$

То же самое, как дисперсия, но в тех же единицах, что и данные. То есть, если в предыдущем примере мы считали бы выборку в рублях, то у нас получились бы рубли в квадрате (дисперсия), а стандартное отклонение показывает значение в рублях. Интуитивно: «в среднем, насколько каждое значение отличается от центра».

Особенности:

- Также чувствительна к выбросам.
- Хорошо работает при нормальном распределении.

- Часто используется для оценки стабильности или волатильности (изменчивости).

Пример поведения:

Представим, что мы замерили время ответа сервера в миллисекундах (мс)

$$X = \{100, 110, 95, 105, 120, 200\}$$

1. Рассчитаем среднее

$$\bar{x} = \frac{100+110+95+105+120+200}{6} = \frac{730}{6} \sim 121.7 \text{ мс}$$

2. Подсчитаем отклонение каждого числа от среднего

$$x_i - \bar{x} = \{-21.7, -11.7, -26.7, -16.7, -1.7, 78.3\}$$

3. Возведем отклонения в квадрат

$$(x_i - \bar{x})^2 = \{470.89, 136.89, 712.89, 278.89, 2.89, 6130.89\}$$

4. Рассчитаем дисперсию

$$D(x) = \frac{470.89+136.89+712.89+278.89+2.89+6130.89}{6} = \frac{7733.34}{6} = 1288.89 \text{ мс}^2$$

$$\sigma = \sqrt{1288.89} = 35.9 \text{ мс}$$

Результат: Среднее время ответа ~122мс, а СКО (σ) ~36мс, что показывает, что большинство запросов отклоняется от среднего ± 36 мс. Видно, что значение 200мс сильно увеличивает СКО.

Вопрос 5:

Найдите дисперсию чисел для набора данных ниже:

$$X = \{5, 7, 9, 11, 13\}$$

Вопрос 6:

Рассчитайте, как изменится дисперсия, если к каждому числу прибавить 10?

Как изменится дисперсия, если каждое число умножить на 3?

3. Межквартильный размах (IQR)

$$IQR = [Q_3 - Q_1]$$

Также известен как интерквартильный размах. Показывает диапазон, в котором лежат средние 50% значений.

Особенности:

- Лучший выбор при наличии асимметричных распределений или выбросов.
- Используется в boxplot-ах (удобен для проверки статистически значимых различий).


Пример поведения:

Есть два сайта:

- А: IQR по отклику 60–40 мс.
- В: IQR 140–40 мс.

Вывод: второй сайт менее предсказуем, хотя средние значения могут быть одинаковыми.

Инфографика 2 — box-plot



Описание:

Перед нами box-plot (также известен как «ящик с усами»), визуализирующий распределение **ежемесячных доходов сотрудников** в трех отделах компании. Каждая «коробка» показывает:

- **Медиану** (горизонтальная линия внутри ящика),
- **Межквартильный размах (IQR)** — ширина ящика от Q_1 (25% выборки) до Q_3 (75% выборки),
- **Усы** — распространение типичных значений, их граница определяется по формуле: $lower_bound = Q_1 - 1.5 * IQR$, $upper_bound = Q_3 + 1.5 * IQR$.

То есть плюс-минус полтора квартильных размаха от границ ящика. 1.5 подобрано эмпирически Джоном Тьюки, что в целом соответствует идее «давайте охватим 99% выборки этой границей», с тех пор это значение исторически зафиксировано для данного представления. Однако, вам ничего не мешает задать другое значение (то есть, не 1.5), главное ответьте себе на вопрос «зачем?».

- **Отдельные точки** — выбросы (слишком высокие/низкие доходы).

Что видно:

1. **Отдел А** — стабильный: узкий IQR, отсутствуют выбросы.
2. **Отдел В** — доходы сильно варьируются: широкий разброс, разброс внутри ящика.
3. **Отдел С** — выбросы вверх: у 10 сотрудников доходы значительно превышают медиану → возможно, премии или бонусы.

Выводы:

- **Медиана** отражает «типичный» доход.
- **IQR** показывает стабильность выплат.
- **Выбросы** важны для выявления аномалий: супербонусов, нестабильности или ошибок в данных.

Квантили и квартили:

- Q_1 — первый квартиль (25% данных ниже него).
- Q_2 — медиана (50% данных ниже него).
- Q_3 — третий квартиль (75% данных ниже него).

- Q4 — так называют весь диапазон до максимума (100%).

Вопрос 7:

Сколько данных находится в диапазоне Q3 и Q1?

Выберите один правильный вариант:

- A. 15%
- B. 25%
- C. 50%
- D. 75%

Вопрос 8:

Сколько данных находится в диапазоне Q4 и Q2?

Выберите один правильный вариант:

- A. 15%
- B. 25%
- C. 50%
- D. 75%

6. Корреляция: идея, знак, величина (и предостережение)

Когда мы говорим:

«Чем больше человек тренируется, тем лучше он играет в теннис», — мы интуитивно описываем корреляцию — статистическую взаимосвязь между двумя величинами.

Что такое корреляция?

Корреляция — это статистическая мера, которая показывает:

- направление связи (прямая или обратная),
- силу связи между двумя переменными.

Один из самых известных способов измерить корреляцию — это коэффициент Пирсона (r):

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

Где:

y_i, x_i — значения переменных, связь которых проверяем;

$\bar{y}, \bar{x}$ — средние значения этих переменных.

Интуиция:

Когда мы смотрим на коэффициент корреляции Пирсона, нас интересует одно простое явление: «Если одна величина растёт, растёт ли в это же время и вторая?»

Причём важно не просто растёт или падает, а насколько они согласованно это делают. Представьте, что две переменные — это два человека, и мы наблюдаем, идут ли они в одну сторону, с одинаковым шагом и без отставаний.

Как это проверяется:

1. Сравниваем отклонения от среднего

Мы не берём сами значения переменных — например, цену в рублях и долларах — потому что у них могут быть разные масштабы.

Вместо этого мы смотрим, насколько каждое значение отклоняется от своей средней величины.

Это как если бы мы сказали:

«Этот человек выше среднего на 5 см, а тот — на 3 см. Значит, оба 'вышли за рамки' вверх».

2. **Умножаем эти отклонения**

- о Если оба значения выше среднего — произведение положительное.
- о Если оба ниже среднего — тоже положительное.
- о Если одно выше, другое ниже — произведение отрицательное.

Это и показывает, сонаправлены ли их движения относительно своих центров.

3. **Нормируем (приводим к одному масштабу)**

Чтобы можно было честно сравнивать переменные разных единиц (например, килограммы и метры), мы делим на произведение стандартных отклонений. Это позволяет итоговому значению всегда быть в пределах от -1 до 1 .

Что означает результат?

- **+1** — переменные идут «рука об руку»: одна растёт, другая растёт точно так же.
- **-1** — одна растёт, а вторая зеркально падает.
- **0** — движения хаотичны, нет никакой четкой **линейной** связи.

Таким образом, коэффициент Пирсона показывает, насколько две величины «шагают в такт» относительно своих собственных средних значений.

Если один делает большой шаг, а второй — маленький или в другую сторону, «такта» нет.

Пример

Попробуем исследовать связь кол-ва часов подготовки студента к экзамену с набранными баллами на экзамене в итоге, с помощью коэффициента Пирсона.

Студент	Часы подготовки	Баллы
А	2	60
Б	4	70
В	6	75
Г	8	85
Д	10	95

1. Обозначим за X - часы подготовки, а Y - баллы и рассчитаем средние:

$$\bar{X} = \frac{2+4+6+8+10}{5} = 6, \bar{Y} = \frac{60+70+75+85+95}{5} = 77$$

2. Рассчитаем отклонение от средних и произведение отклонений.

X	Y	$X - \bar{X}$	$Y - \bar{Y}$	$(X - \bar{X}) \times (Y - \bar{Y})$
2	60	-4	-17	68
4	70	-2	-7	14
6	75	0	-2	0
8	85	2	8	16
10	95	4	18	72

3. Сумма произведений отклонений от средних: $\sum (X - \bar{X}) \times (Y - \bar{Y}) = 170$

4. Посчитаем знаменатель:

$$\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} = \sqrt{40} \sim 6.33, \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} = \sqrt{730} \sim 27.02$$

5. Всё готово для расчета корреляции:

$$r = \frac{170}{6.33 \cdot 27.02} \sim 0.994$$

Результат: получили почти идеальную линейную связь.

Вопрос 9:

Что будет, если данные по баллам отсортировать по убыванию (в обратном порядке) — как изменится корреляция?

Выберите один правильный вариант:

- A. Будет близка к -1 .
- B. Будет близка к 0 .
- C. Будет близка к 1 .

Особенности применения**1. Корреляция $\neq$ причинность**

Даже если $r=0.99$, это не значит, что одно влияет на другое. Обратите внимание на интуицию. Мы отвечаем на вопрос о сонаправленности, но никак не на вопрос о причинно-следственной связи.

2. Подходит только для количественных данных

Для порядковых и номинальных переменных используют другие методы (например, Спирмен или Крамер).


3. Линейная зависимость

Коэффициент Пирсона хорошо работает только при линейной связи. Поэтому, если корреляция равна 0 , это не значит, что связи нет вообще, она может быть, но нелинейная.

4. Устойчивость к выбросам — низкая

Один выброс может сильно изменить значение r . Всегда проверяйте график (scatter-plot (см. ниже))!

Инфографика 3



Описание:

Перед нами scatter-plot, где каждая точка — это студент.

- Ось X: количество часов подготовки в неделю.
- Ось Y: баллы за экзамен.
- Красная линия — линия наименьших квадратов (ЛНК), то есть тренд.

Что видно:


- Общая тенденция положительная: чем больше студент готовился, тем выше его результат.
- Однако заметен разброс: студенты с одинаковым временем подготовки могут показать разные баллы.
- Это отражает то, что подготовка влияет, но не является единственным фактором успеха.

Выводы:

- Наблюдается сильная положительная линейная корреляция ($r \sim 0.86$).

- Подготовка играет роль, но есть и другие переменные (качество подготовки, стресс).

Инфографика 4



Описание:

Перед нами снова scatter-plot, но уже без линии тренда.

- Ось X и ось Y — две абстрактные переменные.
- Каждая точка — одно наблюдение.

Что видно:

- Точки образуют облако, не выстраиваясь в какую-либо линию.
- Нет очевидного наклона вверх или вниз.

Выводы:

- Корреляция близка к нулю ($r \sim -0.04$).
- Переменные изменяются независимо друг от друга.

Ключи к вопросам

Вопрос 1: Чему равно среднее значение для набора данных ниже?

$$X = \{12, 13, 13, 14, 14, 15, 16, 100\}$$

Выберите один правильный вариант:

A. 13.9

При выборе неверного: «Это среднее без учёта выброса. Попробуйте пересчитать сумму всех элементов и разделить на 8.»

B. 14

При выборе неверного: «Это медиана, а не среднее.»

C. 24.6

При выборе верного: «Правильно! Среднее сместилось из-за выброса 100.»

Вопрос 2: Для того же набора данных чему равна медиана?

Выберите один правильный вариант:

A. 13

При выборе неверного: «Нет, это мода. Медиана — значение(я), стоящее в середине упорядоченного ряда.»

B. 14

При выборе верного: «Верно! При четном количестве элементов медиана — это среднее двух центральных значений (14 и 14).»

C. 24.6

При выборе неверного: «Это среднее, а не медиана.»

Вопрос 3: Какая мода у этого же набора данных?

Выберите один правильный вариант:

A. 13 и 14

При выборе верного: «Да! В ряду есть два наиболее часто встречающихся значения: 13 и 14.»

B. 14 и 15

При выборе неверного: «Посмотрите внимательнее: 15 встречается только один раз.»

C. 100

При выборе неверного: «Это выброс, он встречается только один раз.»

Вопрос 4: Подумайте, что изменится, если убрать выброс (100), и сделайте вывод, какой показатель устойчивее к выбросам.

Правильный ответ:

1. Если убрать выброс (100),

Среднее: $\frac{12+13+13+14+14+15+16}{7} \sim 13.86$

Медиана: 14

Мода: {13, 14}

2. Среднее сильно смещается выбросами: было 24.6 → стало 13.9.

Медиана и мода почти не изменились (14 и 13/14).

Вопрос 5: Найдите дисперсию чисел для набора данных ниже:

$$X = \{5, 7, 9, 11, 13\}$$

Правильный ответ: 8

Решение:

1. Рассчитаем среднее

$$\bar{x} = \frac{5+7+9+11+13}{5} = \frac{45}{5} = 9$$

2. Квадрат отклонений

$$(x_i - \bar{x})^2 = \{16, 4, 0, 4, 16\}$$

3. Рассчитаем дисперсию

$$D(x) = \frac{16+4+0+4+16}{5} = \frac{40}{5} = 8$$

Вопрос 6: Рассчитайте, как изменится дисперсия, если к каждому числу прибавить 10?

Как изменится дисперсия, если каждое число умножить на 3?

Правильный ответ:

1. Как изменится дисперсия, если к каждому числу прибавить 10?

- Рассчитаем среднее

$$\bar{x} = \frac{15+17+19+21+23}{5} = \frac{95}{5} = 19$$

- Квадрат отклонений

$$(x_i - \bar{x})^2 = \{16, 4, 0, 4, 16\}$$

- Рассчитаем дисперсию

$$D(x) = \frac{16+4+0+4+16}{5} = \frac{40}{5} = 8$$

Ответ: не изменится

2. Как изменится дисперсия, если каждое число умножить на 3?

- Рассчитаем среднее

$$\bar{x} = \frac{15+21+27+33+39}{5} = \frac{135}{5} = 27$$

- Квадрат отклонений

$$(x_i - \bar{x})^2 = \{144, 36, 0, 36, 144\}$$

- Рассчитаем дисперсию

$$D(x) = \frac{144+36+0+36+144}{5} = \frac{360}{5} = 72 = 3^2 * 8$$

Ответ: увеличится в $3^2 = 9$ раз

Вопрос 7: Сколько данных находится в диапазоне Q3 и Q1?

А. 15%

- B. 25%
- C. 50%
- D. 75%

Комментарий при верном ответе: Между Q1 и Q3 лежит 50% данных — это называется межквартильный размах

Вопрос 8: Сколько данных находится в диапазоне Q4 и Q2?

- A. 15%
- B. 25%
- C. 50%
- D. 75%

Комментарий: Между Q2 и Q4 (т.е. медианой и максимумом) лежит 50% данных. Точно так же между Q1 и Q2 лежит 25%, между Q2 и Q3 – ещё 25%.

Вопрос 9: Что будет, если данные по баллам отсортировать по убыванию (в обратном порядке) - как изменится корреляция?

- A. Будет близка к -1.

Верно. Чем больше часов на подготовку, тем меньше балл. Связь осталась той же, только поменялось направление.

- B. Будет близка к 0.

Неверно. Когда 0 — это означает, что связи нет. Мы уже считали корреляцию и она сильная.

- C. Будет близка к 1.

Неверно. Это соответствует исходным данным.